

SheetMusic: Plataforma para la Enseñanza Adaptativa de Teoría Musical mediante un Modelo que Integra un Grafo de Conocimiento y Deep Reinforcement Learning

Vicente Alves

*Escuela de Ingeniería Civil en Informática
Universidad Austral de Chile*

Valdivia, Chile

vicente.alves@alumnos.uach.cl

Fernando Inzulza

*Escuela de Ingeniería Civil en Informática
Universidad Austral de Chile*

Valdivia, Chile

fernando.inzulza@alumnos.uach.cl

Luis Veas-Castillo

*Instituto de Informática
Universidad Austral de Chile*

Valdivia, Chile

luis.veasc@inf.uach.cl

Christian Lazo

*Instituto de Informática
Universidad Austral de Chile*

Valdivia, Chile

clazo@inf.uach.cl

Abel Mansilla

*Facultad de Arquitectura y Artes
Universidad Austral de Chile*

Valdivia, Chile

abel.mansilla@uach.cl

Abstract—La enseñanza de la teoría musical en el contexto escolar enfrenta importantes desafíos derivados de la reducción de la carga horaria, la discontinuidad curricular y la heterogeneidad en los conocimientos previos de los estudiantes. Aunque existen diversas plataformas digitales de apoyo al aprendizaje musical, estas presentan una limitada capacidad de adaptación pedagógica y carecen de mecanismos que representen explícitamente las relaciones de dependencia entre los contenidos de aprendizaje.

Este trabajo propone un modelo de aprendizaje adaptativo que integra un Grafo de Conocimiento Dirigido Acíclico (DAG) para representar las dependencias pedagógicas entre conceptos de teoría musical y un agente basado en Deep Reinforcement Learning (DRL), implementado mediante el algoritmo *Proximal Policy Optimization (PPO)*, encargado de recomendar dinámicamente la siguiente actividad de aprendizaje de acuerdo con el estado de conocimiento de cada estudiante. Para facilitar el entrenamiento del agente, el modelo combina una etapa inicial de *Behavior Cloning*, basada en estrategias pedagógicas definidas sobre el DAG, con un proceso posterior de aprendizaje por refuerzo en un entorno de simulación.

El modelo fue implementado en SheetMusic, una plataforma web progresiva orientada al aprendizaje adaptativo de teoría musical y al seguimiento pedagógico de los estudiantes por parte de los docentes. La propuesta se evaluó mediante un piloto de factibilidad de 28 días con 28 estudiantes, sin grupo control ni línea base externa, junto con una evaluación de aceptación tecnológica con docentes de la Región de Los Ríos, Chile.

Los resultados preliminares muestran una mejora aproximada del 20% en la mediana del nivel de *proficiency* de los estudiantes, acompañada de una alta percepción de usabilidad ($SUS = 82.5/100$) y una positiva aceptación tecnológica por parte de los docentes ($TAM = 3.75/5$ en utilidad percibida y $4.00/5$ en facilidad de uso). Dado que no se aplicaron pruebas de significancia estadística, estos resultados se interpretan como evidencia preliminar de factibilidad y no como una demostración de la efectividad pedagógica del componente DRL.

Index Terms—Aprendizaje Adaptativo, Deep Reinforcement

Learning, Grafo de Conocimiento, Recomendación Adaptativa, Teoría Musical, Sistemas Inteligentes Educativos.

I. INTRODUCCIÓN

La formación musical escolar desempeña un rol fundamental en el desarrollo cognitivo, creativo y crítico de los estudiantes. Sin embargo, durante las últimas décadas la enseñanza de la música en Chile ha experimentado una progresiva reducción de su presencia dentro del currículo escolar. Decretos ministeriales como el N.º 2960 y el N.º 628 disminuyen la carga horaria destinada a la asignatura a medida que los estudiantes avanzan en su trayectoria escolar, obligando a compartir horas con Artes Visuales o relegando la música a un plan electivo en los niveles superiores [1], [2].

Esta disminución de la carga horaria ha generado dos problemas relevantes para el proceso de enseñanza-aprendizaje de la teoría musical:

- 1) **Discontinuidad curricular y heterogeneidad del aprendizaje.** La reducción de horas y la falta de continuidad en los programas provocan que los estudiantes lleguen a cursos superiores con importantes diferencias en sus conocimientos musicales, dificultando el trabajo del docente y el desarrollo de actividades homogéneas dentro del aula [3].
- 2) **Limitada disponibilidad de herramientas adaptativas para el contexto escolar.** Aunque existen plataformas digitales orientadas al aprendizaje musical, como Yousician o Simply Piano, estas han sido diseñadas principalmente para contextos de autoaprendizaje, presentan escasa alineación con el currículo escolar chileno y utilizan rutas de aprendizaje predominantemente lineales, sin

considerar explícitamente las dependencias pedagógicas entre los contenidos ni las necesidades particulares de cada estudiante [4]–[6].

Como consecuencia, los docentes enfrentan cursos con niveles de conocimiento heterogéneos y las herramientas tecnológicas disponibles adaptan limitadamente las actividades según el progreso de cada estudiante. Esta situación evidencia la necesidad de modelos computacionales capaces de representar explícitamente la estructura del dominio de conocimiento y utilizar dicha representación para personalizar el proceso de enseñanza.

En este contexto surge la siguiente pregunta de investigación:

¿Cómo desarrollar un modelo computacional de aprendizaje adaptativo capaz de recomendar dinámicamente actividades de teoría musical de acuerdo con el progreso del estudiante y la estructura pedagógica del dominio?

Se plantea como hipótesis exploratoria que la integración de una representación explícita del conocimiento pedagógico con un modelo basado en *Deep Reinforcement Learning* (DRL), capaz de aprender políticas de decisión adaptativas a partir de la interacción con el entorno [7], [8], permite generar recomendaciones personalizadas que pueden favorecer el proceso de aprendizaje de teoría musical, ajustando dinámicamente la secuencia de actividades de acuerdo con el progreso individual del estudiante y las dependencias existentes entre los contenidos.

Para explorar esta hipótesis se desarrolló **SheetMusic**, una plataforma que materializa el modelo propuesto e incorpora herramientas de seguimiento pedagógico que permiten al docente monitorear el progreso individual de sus estudiantes.

Las principales contribuciones de este trabajo son las siguientes:

- La formalización del dominio de teoría musical mediante un Grafo de Conocimiento Dirigido Acíclico que representa explícitamente las dependencias pedagógicas entre los contenidos.
- El desarrollo de un modelo de aprendizaje adaptativo basado en *Deep Reinforcement Learning*, capaz de recomendar dinámicamente actividades de acuerdo con el estado de aprendizaje de cada estudiante.
- La implementación del modelo en la plataforma **SheetMusic**, integrando el motor inteligente dentro de una arquitectura distribuida orientada al aprendizaje adaptativo.
- La evaluación piloto de factibilidad del modelo con estudiantes y docentes de la Región de Los Ríos, que permitió caracterizar el desempeño observado del modelo adaptativo y la aceptación tecnológica de la plataforma.

El resto del artículo se organiza de la siguiente manera. La Sección II presenta los trabajos relacionados y el estado del arte. La Sección III describe el modelo propuesto y la arquitectura de **SheetMusic**. La Sección IV presenta la validación experimental y la Sección V los resultados obtenidos, incluyendo sus limitaciones y las consideraciones éticas del

estudio. Finalmente, la Sección VI expone las conclusiones y las principales líneas de trabajo futuro.

II. TRABAJOS RELACIONADOS Y ESTADO DEL ARTE

El aprendizaje adaptativo de teoría musical constituye un área interdisciplinaria donde convergen la educación musical, la inteligencia artificial y los sistemas inteligentes de apoyo al aprendizaje. En esta sección se revisan las principales plataformas existentes, los avances recientes en representación del conocimiento y aprendizaje adaptativo, y la brecha científica que motiva el presente trabajo.

A. Plataformas de Aprendizaje Musical

En el ámbito comercial y de acceso abierto destacan plataformas como *Yousician*, *Simply Piano*, *Teoria.com* y *Duolingo Music*. Estas herramientas han contribuido significativamente a masificar el acceso al aprendizaje musical mediante experiencias gamificadas e interfaces interactivas. Sin embargo, presentan diversas limitaciones para su incorporación como herramientas de apoyo en el contexto escolar:

- **Alineación curricular e idioma:** La mayoría de estas plataformas fueron desarrolladas para mercados angloparlantes y no se encuentran alineadas con las bases curriculares del sistema educativo chileno ni latinoamericano [4], [5].
- **Apoyo al proceso docente:** Su diseño está orientado principalmente al autoaprendizaje, careciendo de mecanismos que permitan al profesor monitorear el progreso de los estudiantes, identificar brechas de aprendizaje o asignar actividades diferenciadas [4]–[6].
- **Secuencias de aprendizaje rígidas:** Generalmente organizan los contenidos mediante rutas de aprendizaje predefinidas o predominantemente lineales, limitando la personalización del recorrido formativo y la incorporación de representaciones explícitas de las dependencias pedagógicas entre los contenidos [5], [6].

B. Representación del Conocimiento y Aprendizaje Adaptativo

La representación explícita del dominio de conocimiento constituye un componente fundamental en los sistemas de aprendizaje adaptativo, ya que permite modelar las relaciones de dependencia entre conceptos, definir prerequisites y estructurar trayectorias de aprendizaje coherentes [9]. En teoría musical esta representación resulta especialmente relevante, pues la comprensión de conceptos avanzados depende del dominio previo de conocimientos fundamentales.

Paralelamente, la incorporación de técnicas de Inteligencia Artificial en educación ha crecido sostenidamente, incluyendo la generación automática de contenidos, el entrenamiento auditivo y la evaluación del desempeño en el ámbito musical [4]. En particular, el *Deep Reinforcement Learning* (DRL) ha demostrado ser una alternativa para abordar problemas de decisión secuencial y personalización del aprendizaje, permitiendo aprender políticas de recomendación a partir de la interacción con el entorno [7], [8]. Entre los algoritmos

más utilizados destacan *Deep Q-Network* (DQN) y *Proximal Policy Optimization* (PPO), ampliamente empleados para el aprendizaje de políticas en problemas de decisión secuencial.

La evidencia disponible sobre secuenciación instruccional es promisorio pero condicionada. La revisión de Doroudi *et al.* reporta que más de la mitad de los estudios comparativos encontró que las políticas inducidas por aprendizaje por refuerzo superaron a sus líneas base, aunque dichos beneficios aparecen principalmente cuando la política se restringe con teoría pedagógica y cognitiva [10]. En esta dirección, Bassen *et al.* utilizaron aprendizaje por refuerzo para programar dinámicamente actividades educativas [11], y Amin *et al.* propusieron un marco de rutas de aprendizaje secuenciales con recomendación adaptativa basada en aprendizaje por refuerzo [12]. No obstante, estos trabajos suelen definir manualmente los espacios de estados y acciones, no incorporan una representación explícita de los prerrequisitos curriculares del dominio y, en varios casos, se evalúan en escenarios simulados o de corta duración. En educación musical, las investigaciones revisadas se concentran en composición asistida, entrenamiento auditivo o herramientas de apoyo institucional [5], [6].

En síntesis, los trabajos revisados no integran simultáneamente una representación explícita del conocimiento disciplinar y un mecanismo de decisión basado en aprendizaje por refuerzo para recomendar trayectorias adaptativas en teoría musical.

C. Brecha Científica

Del análisis del estado del arte se observa que las soluciones existentes abordan parcialmente el problema del aprendizaje adaptativo: las plataformas comerciales ofrecen experiencias gamificadas y los trabajos de investigación aplican técnicas de inteligencia artificial, pero no se identifican propuestas que integren simultáneamente:

- 1) Una representación explícita del conocimiento de teoría musical que modele las dependencias pedagógicas entre los contenidos.
- 2) Un modelo basado en *Deep Reinforcement Learning* capaz de recomendar dinámicamente la siguiente actividad de aprendizaje de acuerdo con el progreso del estudiante.
- 3) Una plataforma que permita implementar dicho modelo en un entorno real, incorporando además herramientas de seguimiento pedagógico para el docente.

Esta brecha evidencia la necesidad de desarrollar modelos computacionales que integren una representación explícita del conocimiento con técnicas de aprendizaje adaptativo, permitiendo recomendar dinámicamente actividades de teoría musical de acuerdo con el progreso individual del estudiante y la estructura pedagógica del dominio.

III. SOLUCIÓN PROPUESTA

La solución propuesta consiste en un modelo computacional de aprendizaje adaptativo para la enseñanza de teoría musical, diseñado para recomendar dinámicamente actividades de acuerdo con el progreso individual del estudiante y la

estructura pedagógica del dominio. El modelo se estructura sobre tres componentes complementarios: (i) un Grafo de Conocimiento Dirigido Acíclico (DAG), encargado de representar explícitamente las dependencias entre los conceptos musicales; (ii) un agente basado en *Deep Reinforcement Learning* (DRL), responsable de aprender una política de recomendación adaptativa; y (iii) la plataforma **SheetMusic**, que implementa el modelo y proporciona las funcionalidades necesarias para estudiantes y docentes.

El modelo fue implementado en **SheetMusic**, una plataforma web progresiva que articula la experiencia de aprendizaje del estudiante, las herramientas de seguimiento pedagógico del docente y un microservicio inteligente encargado de generar las recomendaciones. La separación entre la representación del conocimiento, el motor de decisión y la plataforma permite desacoplar la lógica adaptativa de los componentes de presentación, persistencia y procesamiento inteligente.

A. Modelo Funcional de SheetMusic

La implementación del modelo de aprendizaje adaptativo se materializa mediante **SheetMusic**, una plataforma web progresiva diseñada para apoyar tanto el proceso de aprendizaje de los estudiantes como el seguimiento pedagógico realizado por los docentes. Desde una perspectiva funcional, la plataforma define dos actores principales: el *Estudiante*, quien interactúa con el sistema mediante actividades de estudio, práctica y seguimiento de su progreso; y el *Profesor*, responsable de la gestión de cursos, la administración de estudiantes, la asignación de actividades y el monitoreo del desempeño académico.

La Figura 1 presenta la visión funcional de SheetMusic mediante un diagrama de casos de uso unificado, mostrando las principales funcionalidades disponibles para ambos perfiles de usuario. Esta visión funcional establece el contexto operativo sobre el cual se implementa el modelo computacional de aprendizaje adaptativo descrito en las siguientes subsecciones.




Fig. 1. Modelo funcional de la plataforma SheetMusic, mostrando los principales casos de uso para los perfiles de Estudiante y Profesor.

B. Grafo de Conocimiento Musical

La representación explícita del dominio de conocimiento constituye uno de los pilares del modelo de aprendizaje adaptativo propuesto, ya que permite formalizar computacionalmente las relaciones pedagógicas existentes entre los distintos contenidos de teoría musical. En lugar de organizar los ejercicios mediante una secuencia fija, el modelo representa el dominio como una estructura de dependencias que permite

identificar prerequisites, establecer trayectorias de aprendizaje coherentes y restringir las recomendaciones a actividades pedagógicamente válidas [9].

Con este propósito, el dominio de la teoría musical se formalizó mediante un **Grafo de Conocimiento Dirigido Acíclico (DAG)** definido como:

$$G = (V, E) \quad (1)$$

donde V representa el conjunto de unidades de conocimiento (nodos) y E el conjunto de aristas dirigidas que modelan las relaciones de dependencia pedagógica entre dichos conceptos. En la implementación completa del sistema, el grafo está compuesto por 23 unidades de conocimiento distribuidas en cinco niveles de dificultad y 29 relaciones de dependencia. Estas dependencias representan prerequisites recomendados para favorecer una progresión lógica del aprendizaje, aunque no constituyen restricciones absolutas, ya que un estudiante puede acceder a contenidos posteriores cuando demuestra un nivel de dominio suficiente durante el proceso de evaluación adaptativa.

Con el propósito de facilitar la validación experimental del modelo, en este trabajo se empleó un subgrafo compuesto por cuatro unidades de conocimiento fundamentales de teoría musical: *Notas y Ritmo*, *Intervalos*, *Escala Mayores y Menores* y *Acordes (Triadas)*. Estos conceptos permiten representar las principales relaciones de dependencia pedagógica presentes en el dominio y constituyen una base suficiente para evaluar el comportamiento del sistema de recomendación.




Fig. 2. Subgrafo del Grafo de Conocimiento Musical utilizado durante la validación experimental. Cada nodo representa una unidad de conocimiento y cada arista dirigida representa una relación de prerequisite pedagógico entre conceptos.

La Figura 2 muestra el subgrafo utilizado durante la validación. En esta representación, las aristas dirigidas indican los prerequisites pedagógicos entre los distintos conceptos, permitiendo establecer una progresión lógica del aprendizaje desde contenidos básicos hacia unidades de mayor complejidad.

Para que el agente de recomendación pueda determinar las actividades disponibles en cada instante del proceso de aprendizaje, cada nodo del grafo mantiene un estado asociado al progreso alcanzado por el estudiante. Dicho estado puede corresponder a una unidad bloqueada (*locked*), disponible

(*available*), en desarrollo (*active*) o completada (*done*), según la siguiente definición:

$$State(v_i) = \begin{cases} \text{locked,} & \exists u \in Pred(v_i) \mid Prog(u) \neq \text{done} \\ \text{done,} & Prog(v_i) = \text{done} \\ \text{active,} & Prog(v_i) = \text{in_progress} \\ \text{available,} & \text{en otro caso} \end{cases} \quad (2)$$

Esta representación no determina directamente cuál será la siguiente actividad recomendada, sino que define el conjunto de actividades pedagógicamente válidas para el estado actual del estudiante. Sobre este espacio de decisión opera posteriormente el agente basado en *Deep Reinforcement Learning*, encargado de seleccionar la recomendación que maximiza el progreso esperado del proceso de aprendizaje.

C. Modelo de Recomendación Basado en Deep Reinforcement Learning

Una vez representado el dominio de conocimiento mediante el Grafo de Conocimiento Musical, el problema de recomendación adaptativa se modela como un proceso de decisión secuencial, donde un agente basado en *Deep Reinforcement Learning* (DRL) selecciona dinámicamente la siguiente actividad de aprendizaje considerando el estado actual del estudiante y las restricciones pedagógicas definidas por el DAG. El objetivo del agente consiste en aprender una política de recomendación que maximice el progreso esperado del estudiante, equilibrando la consolidación de conocimientos, la exploración de nuevos contenidos y la dificultad de los ejercicios.

La implementación del agente se desarrolló utilizando *Stable-Baselines3* (versión 2.0.1) sobre *Gymnasium* (versión 1.2.0), siguiendo el esquema clásico de interacción *agent-environment loop*, donde el agente observa el estado del estudiante, selecciona una actividad, recibe retroalimentación y actualiza iterativamente su política de decisión.

1) *Entorno de Aprendizaje*: El entorno de entrenamiento, denominado *MusicLearningEnv*, fue implementado como una subclase de *gymnasium.Env*. Cada interacción corresponde a un episodio donde el agente selecciona un ejercicio de teoría musical, observa la respuesta del estudiante y recibe una recompensa asociada al impacto pedagógico de dicha decisión.

2) *Espacio de Observaciones*: El estado del estudiante se representa mediante la clase *UserState*, la cual encapsula la información necesaria para describir su situación de aprendizaje. Entre los atributos considerados se encuentran: **knowledge** (nivel de dominio de cada concepto), **accuracy** (precisión histórica), **attempts** (cantidad de intentos por concepto), **streak** (racha de aciertos o errores), **last_exercise_difficulty** (última dificultad presentada), **time_since_last_practice** (tiempo desde la última práctica) y **recent_performance_trend** (tendencia reciente de desempeño).

Para el proceso de inferencia, el nivel de dominio se discretiza utilizando un umbral de proficiencia de 0.5:

$$o_i = \begin{cases} 1, & \text{si } proficiency_i \geq 0.5 \\ 0, & \text{en otro caso} \end{cases} \quad (3)$$

obteniéndose un vector binario (`MultiBinary`) que resume el estado de conocimiento del estudiante y constituye la entrada utilizada por el agente DRL.

3) *Espacio de Acciones*: El espacio de acciones se define como un conjunto discreto (`Discrete(N)`), donde cada acción corresponde a un ejercicio específico de teoría musical asociado a uno de los nodos del DAG mediante la estructura `skill_mapping`. Esta representación desacopla el modelo de aprendizaje del conjunto de ejercicios disponible, permitiendo incorporar nuevos contenidos o eliminar ejercicios existentes sin modificar la estructura del agente.

4) *Función de Recompensa*: La política del agente se aprende mediante la maximización de una recompensa acumulada que refleja el equilibrio entre el progreso pedagógico del estudiante y la calidad de las recomendaciones generadas. Para ello, se definió una función de recompensa compuesta por incentivos y penalizaciones, orientada a favorecer trayectorias de aprendizaje efectivas y evitar decisiones pedagógicamente inadecuadas.

$$\begin{aligned} R = & 1.0 \mathbb{I}(\text{correcto}) + 0.5 \mathbb{I}(\text{mejoría}) \\ & + 0.5 \mathbb{I}(|d - d^*| \leq 1) - 0.3 \mathbb{I}(|d - d^*| > 2) \\ & + 0.2 \mathbb{I}(\text{nodo poco practicado}) + 0.1 \mathbb{I}(\text{ejercicio nuevo}) \end{aligned} \quad (4)$$

donde $d^* = proficiency \times 10$ representa la dificultad esperada para el nivel actual del estudiante.

Los términos positivos incentivan respuestas correctas, mejoras respecto al desempeño previo, ejercicios cercanos a la zona de desarrollo proximal, exploración de contenidos poco practicados y variedad en las actividades recomendadas. Por otra parte, el agente recibe penalizaciones cuando recomienda ejercicios cuya dificultad resulta inadecuada para el nivel del estudiante, cuando repite innecesariamente un mismo ejercicio o cuando intenta acceder a contenidos cuyos prerrequisitos pedagógicos definidos por el DAG aún no han sido alcanzados. En consecuencia, el agente aprende simultáneamente a maximizar el progreso esperado del estudiante y a minimizar recomendaciones pedagógicamente inconsistentes.

5) *Selección del Algoritmo de Aprendizaje*: Con el objetivo de determinar el algoritmo más adecuado para el problema de recomendación adaptativa, se evaluaron dos enfoques ampliamente utilizados en Deep Reinforcement Learning: *Deep Q-Network* (DQN) y *Proximal Policy Optimization* (PPO).

Durante las pruebas experimentales, DQN presentó una convergencia inicial más rápida, alcanzando políticas aceptables después de aproximadamente 120 episodios. Sin embargo, mostró una tendencia a favorecer acciones previamente exitosas, reduciendo la exploración de nuevos contenidos y generando políticas excesivamente conservadoras.

Por el contrario, PPO presentó una convergencia ligeramente más lenta (150–180 episodios), pero desarrolló políticas considerablemente más estables, manteniendo un mejor equilibrio entre exploración y explotación. Además, su arquitectura *actor-critic* y el uso de políticas estocásticas permitieron obtener recomendaciones menos predecibles y más consistentes con la variabilidad esperada en procesos educativos adaptativos. Por estas razones, PPO fue seleccionado como algoritmo de recomendación del sistema.

6) *Estrategia de Entrenamiento*: Debido a que durante las primeras etapas del proyecto no se disponía de datos históricos de interacción suficientes para entrenar el agente mediante aprendizaje por refuerzo, se diseñó una estrategia de entrenamiento en dos etapas.

En primer lugar, se aplicó un cuestionario a estudiantes de enseñanza media para estimar perfiles iniciales de conocimiento y parámetros de aprendizaje. A partir de estos datos se implementó un simulador probabilístico denominado *SyntheticStudent*, capaz de generar trayectorias sintéticas de aprendizaje para distintos perfiles de estudiantes.

Posteriormente, el entrenamiento se realizó mediante un esquema híbrido. Inicialmente se aplicó *Behavior Cloning*, técnica de aprendizaje por imitación utilizada para inicializar una política a partir de demostraciones o decisiones de referencia [13]. En este trabajo, dicha política inicial fue construida utilizando criterios pedagógicos definidos por expertos en teoría musical. Sobre esta política base se ejecutó posteriormente el entrenamiento mediante PPO utilizando aproximadamente 200 000 interacciones simuladas, permitiendo refinar progresivamente la política de recomendación hasta obtener un comportamiento estable y adaptativo.

Este enfoque híbrido combina conocimiento pedagógico explícito, incorporado inicialmente mediante *Behavior Cloning*, con la capacidad de optimización autónoma proporcionada por *Deep Reinforcement Learning*. Como resultado, el agente inicia el proceso de aprendizaje a partir de una política consistente con criterios pedagógicos definidos por expertos y posteriormente la refina mediante interacción con el entorno, obteniendo recomendaciones progresivamente más adaptativas y robustas.

D. Arquitectura Distribuida

La implementación del modelo de aprendizaje adaptativo propuesto se materializa mediante una arquitectura distribuida basada en microservicios, diseñada para desacoplar la interfaz de usuario, la gestión de datos y el motor de inteligencia artificial encargado de generar las recomendaciones adaptativas. Esta separación permite que cada componente evolucione de manera independiente, facilita el escalamiento horizontal del sistema y posibilita incorporar mejoras al modelo de aprendizaje sin modificar la plataforma utilizada por estudiantes y docentes [14], [15].

La Figura 3 presenta la arquitectura general de **SheetMusic**, organizada en tres capas principales: una capa cliente responsable de la interacción con los usuarios, una capa de servicios encargada de la autenticación y persistencia de la información

académica, y una capa de inteligencia donde se ejecuta el modelo basado en *Deep Reinforcement Learning*.




Fig. 3. Arquitectura distribuida de SheetMusic y sus principales componentes.

1) *Componentes de la Arquitectura:* La arquitectura propuesta está compuesta por tres componentes principales:

- **Capa Cliente.** Implementada como una *Progressive Web Application* (PWA) utilizando Ionic React y Capacitor, proporciona la interfaz mediante la cual estudiantes y docentes acceden al material de estudio, resuelven ejercicios, consultan su progreso académico y administran las actividades del curso.
- **Capa de Servicios.** Implementada sobre Supabase y PostgreSQL, administra la autenticación de usuarios mediante *JSON Web Tokens* (JWT), el almacenamiento del historial académico y la comunicación con la aplicación cliente mediante procedimientos remotos (RPC). Asimismo, aplica políticas de seguridad basadas en *Row Level Security* (RLS), garantizando el aislamiento de la información entre estudiantes y docentes [16].
- **Motor de Inteligencia.** Implementado como un microservicio independiente utilizando FastAPI, PyTorch y Stable-Baselines3, recibe el estado actualizado del estudiante, ejecuta el agente basado en PPO y retorna la recomendación del siguiente ejercicio junto con su nivel de dificultad adaptativo.

2) *Flujo de Interacción Distribuida:* La arquitectura implementa dos flujos principales de interacción entre sus componentes. El primero corresponde al acceso al contenido pedagógico y el segundo al proceso de inferencia adaptativa realizado por el agente basado en Deep Reinforcement Learning.

La Figura 4 ilustra el flujo utilizado para el renderizado dinámico del material de aprendizaje. Cuando un estudiante accede a una unidad de conocimiento, la aplicación cliente

solicita el contenido correspondiente mediante procedimientos remotos (RPC) al backend de Supabase. La información es recuperada desde la base de datos utilizando objetos JSONB, los cuales son interpretados por el cliente para construir dinámicamente la interfaz de aprendizaje, incluyendo recursos multimedia, barras de progreso, tarjetas de conceptos clave y elementos de gamificación.



Fig. 4. Renderizado dinámico del contenido pedagógico utilizando objetos JSONB recuperados desde el backend.

Una vez finalizada una actividad, se inicia el segundo flujo de interacción, correspondiente al proceso de recomendación adaptativa. Como se observa en la Figura 5, el cliente envía el resultado del ejercicio al backend, el cual valida la sesión del usuario, actualiza el historial académico y construye el vector de observaciones requerido por el agente DRL. Posteriormente, el microservicio de inteligencia ejecuta el modelo PPO, determina la siguiente recomendación considerando el estado del estudiante y las restricciones impuestas por el Grafo de Conocimiento Musical, y retorna la respuesta al backend. Finalmente, la plataforma presenta al estudiante el siguiente ejercicio junto con su nivel de dificultad adaptativo, completando el ciclo de aprendizaje.




Fig. 5. Flujo distribuido de inferencia entre el cliente, el backend y el motor de Deep Reinforcement Learning.

La arquitectura distribuida propuesta desacopla completamente la representación del conocimiento (DAG), el proceso

de toma de decisiones basado en Deep Reinforcement Learning y la interfaz utilizada por estudiantes y docentes. Como consecuencia, nuevas estrategias de recomendación, funciones de recompensa o modelos de aprendizaje pueden incorporarse al sistema sin modificar la plataforma cliente, favoreciendo la mantenibilidad, escalabilidad y evolución futura de **SheetMusic**.

IV. VALIDACIÓN EXPERIMENTAL

Con el objetivo de validar la propuesta presentada, se diseñó una evaluación que consideró tanto el desempeño del modelo de aprendizaje adaptativo como la percepción de los usuarios respecto de la plataforma **SheetMusic**, estructurada en la definición del escenario experimental, la evaluación mediante métricas objetivas y subjetivas, y el análisis de los resultados obtenidos.

A. Diseño Experimental

La validación se realizó utilizando la versión funcional de **SheetMusic** desarrollada durante el proyecto, en la cual los participantes resolvieron actividades de teoría musical recomendadas por el agente basado en *Deep Reinforcement Learning*. Durante cada sesión se registró automáticamente el estado del estudiante, las recomendaciones del sistema y el progreso alcanzado en las distintas unidades de conocimiento.

El diseño correspondió a un estudio piloto de un solo grupo, con mediciones repetidas de *proficiency* a lo largo del período de uso, sin grupo control ni línea base externa de comparación. Por este motivo, la evaluación no incorporó pruebas de significancia estadística y los resultados se interpretan como evidencia preliminar de factibilidad. Finalizada la interacción, estudiantes y docentes respondieron instrumentos estandarizados con el propósito de evaluar la usabilidad y aceptación de la plataforma.

B. Métricas de Evaluación

La validación experimental consideró dos dimensiones complementarias: (i) el desempeño del modelo de recomendación basado en *Deep Reinforcement Learning* y (ii) la percepción de los usuarios respecto de la plataforma **SheetMusic**.

Evaluación del modelo de recomendación. Para analizar el comportamiento del agente DRL se utilizaron los siguientes indicadores:

- **Progreso de Aprendizaje (Proficiency):** cuantifica la evolución del nivel de dominio alcanzado por el estudiante durante las sesiones de aprendizaje, permitiendo caracterizar el desempeño observado del agente.
- **Tasa de Continuidad:** mide la permanencia del estudiante en el proceso de aprendizaje mediante el número de sesiones realizadas y la continuidad de uso de la plataforma, como estimación indirecta del nivel de compromiso con el sistema.
- **Adaptabilidad de la Dificultad:** evalúa la capacidad del agente para recomendar ejercicios cuya dificultad se mantenga cercana al nivel de competencia del estudiante,

evitando actividades excesivamente complejas o demasiado simples.

Evaluación de la plataforma. Para analizar la experiencia de uso de **SheetMusic** se emplearon instrumentos ampliamente utilizados en la evaluación de sistemas interactivos:

- **Usabilidad (SUS):** se aplicó el cuestionario *System Usability Scale (SUS)* para evaluar la facilidad de uso percibida por los estudiantes [17].
- **Aceptación Tecnológica (TAM):** los docentes respondieron un cuestionario basado en el *Technology Acceptance Model (TAM)*, permitiendo evaluar la utilidad percibida, la facilidad de uso y la intención de utilización futura de la plataforma [18].

V. RESULTADOS

La validación se realizó mediante una prueba piloto con 28 estudiantes de la Región de Los Ríos, Chile: 5 del Conservatorio de Música de la Universidad Austral de Chile y 23 de enseñanza media de la comuna de Corral. Durante 28 días consecutivos, los participantes utilizaron **SheetMusic** para resolver actividades de teoría musical recomendadas por el agente basado en *Deep Reinforcement Learning*, registrándose automáticamente las métricas de interacción, progreso y rendimiento.

A. Resultados del Modelo de Recomendación

La Figura 6 presenta la evolución del nivel de *proficiency* observada en tres perfiles representativos de estudiantes. En los tres casos se aprecia una tendencia ascendente, lo que resulta consistente con el funcionamiento esperado de la política aprendida mediante PPO. Sin embargo, al no disponer de un grupo control ni de una línea base externa, no es posible atribuir el incremento observado de forma específica al componente DRL, ya que otras variables del proceso de aprendizaje podrían haber contribuido a la mejora.




Fig. 6. Evolución del nivel de *proficiency* de tres perfiles representativos de estudiantes durante el piloto.

La continuidad de uso se evaluó mediante el número de sesiones registradas. Como se observa en la Figura 7, la actividad se mantuvo estable durante las tres primeras semanas, acumulando 572 sesiones; la menor actividad registrada en la cuarta semana corresponde al cierre del proceso de recolección de datos y no a una disminución en el uso de la plataforma.

Los principales indicadores obtenidos durante el piloto se resumen en la Tabla I. La mediana del nivel de *proficiency*




Fig. 7. Distribución semanal de las sesiones registradas durante el período de validación.

mostró una mejora aproximada del 20% al comparar las dos primeras semanas de uso con las semanas posteriores, superando la meta inicial del 15%. Este resultado constituye una observación descriptiva del piloto y no una estimación de efecto.

TABLE I
RESUMEN DE LOS PRINCIPALES RESULTADOS OBTENIDOS DURANTE LA VALIDACIÓN DEL MODELO DE RECOMENDACIÓN.

Indicador	Resultado
Participantes	28 estudiantes
Sesiones registradas	572 sesiones
Continuidad de uso	Actividad sostenida durante el período de evaluación
Mejora observada en <i>Proficiency</i>	Incremento aproximado del 20% (meta: 15%)
Alcance de la evidencia	Estudio piloto de un solo grupo, sin grupo control ni pruebas de significancia

En conjunto, los resultados observados son compatibles con una progresión positiva del aprendizaje y con una participación sostenida durante el piloto; no obstante, el diseño empleado no permite aislar la contribución del componente DRL de otros factores del proceso de aprendizaje.

B. Resultados de la Plataforma

La experiencia de uso de **SheetMusic** se evaluó mediante los instrumentos *System Usability Scale* (SUS) y *Technology Acceptance Model* (TAM), cuyos resultados se resumen en la Tabla II.

TABLE II
RESULTADOS DE LA EVALUACIÓN DE USABILIDAD Y ACEPTACIÓN TECNOLÓGICA DE LA PLATAFORMA.

Métrica	Resultado
System Usability Scale (SUS)	82.5 / 100
Future Use Perception (FUP)	4.00 / 5.00

El puntaje obtenido en SUS indica una percepción positiva respecto de la facilidad de uso de la plataforma, mientras que la evaluación de Future Use Perception evidencia una favorable disposición de los participantes a continuar utilizando la herramienta. En conjunto, estos resultados complementan la evaluación del modelo de recomendación, mostrando que la propuesta presenta niveles adecuados de usabilidad y aceptación para su utilización en contextos educativos.

C. Limitaciones y Validez de los Resultados

Los hallazgos presentados deben interpretarse considerando las siguientes limitaciones:

- **Muestra reducida y heterogénea:** la evaluación consideró 28 estudiantes (5 de Conservatorio y 23 de enseñanza media), sin caracterización de sus conocimientos previos, lo que restringe la representatividad de los resultados.
- **Período acotado:** la observación se extendió por 28 días, plazo que no permite analizar la retención de los aprendizajes ni la sostenibilidad del uso en el tiempo.
- **Cobertura parcial del dominio:** la validación utilizó un subgrafo de cuatro unidades de conocimiento de un total de 23, por lo que el comportamiento del agente en el resto del grafo no fue evaluado.
- **Ausencia de grupo control y de línea base:** el diseño correspondió a un estudio de un solo grupo, sin condiciones de comparación ni pruebas de significancia estadística, lo que impide atribuir causalmente la mejora observada al componente DRL.
- **Entrenamiento principalmente simulado:** la política del agente se entrenó con interacciones generadas por el simulador *SyntheticStudent*, por lo que su desempeño en condiciones reales de aula podría diferir del reportado.
- **Aspectos éticos:** la evaluación se realizó sin aprobación previa de un Comité de Ética ni formulario formal de consentimiento, según se detalla a continuación.

D. Consideraciones Éticas

La evaluación piloto se realizó con estudiantes de enseñanza media. Previamente, el docente responsable notificó a los apoderados por correo electrónico y obtuvo su autorización para la participación de los menores. Los estudiantes accedieron voluntariamente a la plataforma mediante un enlace proporcionado por el profesor; la participación no fue obligatoria ni estuvo asociada a consecuencias académicas. En la aplicación se desplegó un aviso de privacidad que indicaba: “los datos recopilados de las sesiones de usuarios son anonimizados y serán utilizados en un estudio científico-tecnológico. Además, en caso de ser menor de edad cuenta con la autorización de sus padres”, garantizando que, incluso entre los menores, se contaba con el consentimiento de los apoderados. La plataforma no solicitó nombre, RUT, edad u otros datos personales directamente identificatorios; el acceso podía realizarse con una dirección de correo no identificatoria y los resultados fueron tratados de forma agregada, sin posibilidad de identificar individualmente a los participantes. La evaluación se realizó sin una aprobación previa de un Comité de Ética ni un formulario formal de consentimiento; esta limitación se incorpora en el manuscrito y los autores han solicitado orientación al comité de ética correspondiente.

VI. CONCLUSIONES Y TRABAJOS FUTUROS

En este trabajo se presentó un modelo computacional de aprendizaje adaptativo para la enseñanza de teoría mu-

sical, el cual integra un Grafo de Conocimiento Dirigido Acíclico (DAG) para representar explícitamente las dependencias pedagógicas del dominio y un agente basado en *Deep Reinforcement Learning* para recomendar dinámicamente actividades de aprendizaje de acuerdo con el progreso individual del estudiante. El modelo se implementó en la plataforma distribuida **SheetMusic**, materializando la propuesta en un entorno educativo real.

Los resultados del piloto son compatibles con la capacidad del agente de recomendación para adaptar la secuencia y la dificultad de los ejercicios al desempeño de cada estudiante, junto con una progresión sostenida del nivel de conocimiento y una participación continua durante el período de evaluación. No obstante, dado que el diseño correspondió a un estudio de un solo grupo, sin grupo control ni pruebas de significancia estadística, estos hallazgos deben interpretarse como evidencia preliminar de factibilidad y no como una demostración de la efectividad pedagógica del componente DRL. Por su parte, la evaluación de usabilidad y aceptación tecnológica evidenció una percepción favorable de la plataforma por parte de sus usuarios, respaldando la viabilidad de la propuesta para su utilización en contextos educativos.

Desde la perspectiva de la Ingeniería Informática, el principal aporte del trabajo corresponde a la integración de una representación explícita del conocimiento pedagógico mediante un DAG con un modelo de aprendizaje por refuerzo profundo, desacoplando la estructura del dominio, la toma de decisiones y la implementación tecnológica. Esta arquitectura facilita la evolución independiente de cada componente, permitiendo incorporar nuevos contenidos, estrategias de recomendación o modelos de inteligencia artificial sin modificar la infraestructura principal.

Con el propósito de favorecer la reproducibilidad científica y la continuidad del proyecto, el código fuente de la plataforma, del motor de recomendación y de los microservicios desarrollados se encuentra disponible públicamente en la organización oficial de GitHub: <https://github.com/Sheetmusic-Team>.

Como trabajo futuro se contempla ampliar el Grafo de Conocimiento Musical a la totalidad de las unidades curriculares de teoría musical, incorporar nuevos modelos de aprendizaje por refuerzo y comparar su desempeño con PPO, integrar evaluación instrumental en tiempo real mediante procesamiento digital de señales (DSP) y desarrollar una validación controlada, con grupo de comparación, pruebas de significancia y acompañamiento de un Comité de Ética, sobre una muestra mayor de estudiantes de distintos establecimientos educacionales del país.

REFERENCES

- [1] Ministerio de Educación de Chile, "Decreto n.º 2960: Establece planes y programas de estudio para establecimientos educacionales con jornada escolar completa diurna (enseñanza básica 1.º a 6.º)," Decreto Supremo, Santiago, Chile, 2012. [Online]. Available: <https://www.bcn.cl/leychile/navegar?idNorma=1048434>
- [2] —, "Decreto n.º 628: Aprueba programas de estudio de séptimo y octavo año de educación básica," Decreto Exento, Santiago, Chile, 2016. [Online]. Available: <https://www.bcn.cl/leychile/Navegar?idNorma=1091910>
- [3] M. A. Chandía Flores, "La educación descalibrada. los problemas de la enseñanza musical en el ciclo medio," Memoria para optar al título de Periodista, Universidad de Chile, Facultad de Comunicación e Imagen, Escuela de Periodismo, Santiago, Chile, 2025.
- [4] M. García-Sancho and D. Pérez, "IA aplicada a educación musical," *IEEE Education Review*, vol. 9, pp. 1–15, 2025.
- [5] F. Alrowais, M. Alotaibi, and A. Alqahtani, "Interactive music learning systems using reinforcement learning," *PubMed Central*, 2025. [Online]. Available: <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC11784531>
- [6] X. Li, Y. Zhang, and H. Wang, "Deep reinforcement learning for personalized learning path optimization in music education," *ACM Digital Library*, 2025. [Online]. Available: <https://dl.acm.org/doi/10.1145/3732801.3732827>
- [7] R. S. Sutton and A. G. Barto, *Reinforcement Learning: An Introduction*, 2nd ed. MIT Press, 2018.
- [8] V. Mnih, K. Kavukcuoglu, D. Silver, A. A. Rusu, J. Veness, M. G. Bellemare, A. Graves, M. Riedmiller, A. K. Fidjeland, G. Ostrovski et al., "Human-level control through deep reinforcement learning," *Nature*, vol. 518, no. 7540, pp. 529–533, 2015.
- [9] R. Manrique, B. Pereira, and O. Mariño, "Exploring knowledge graphs for the identification of concept prerequisites," *Smart Learning Environments*, vol. 6, no. 21, 2019.
- [10] S. Doroudi, V. Alevan, and E. Brunskill, "Where's the reward? A review of reinforcement learning for instructional sequencing," *International Journal of Artificial Intelligence in Education*, vol. 29, no. 4, pp. 568–620, 2019.
- [11] J. Bassen, B. Balaji, M. Schaarschmidt, C. Thille, J. Painter, D. Zimmaro, A. Games, E. Fast, and J. C. Mitchell, "Reinforcement learning for the adaptive scheduling of educational activities," in *Proceedings of the 2020 CHI Conference on Human Factors in Computing Systems*, 2020, pp. 1–12.
- [12] S. Amin, M. I. Uddin, A. A. Alarood, W. K. Mashwani, A. Alzahrani, and A. Alzahrani, "Smart e-learning framework for personalized adaptive learning and sequential path recommendations using reinforcement learning," *IEEE Access*, vol. 11, pp. 89 769–89 790, 2023.
- [13] T. Osa, J. Pajarinen, G. Neumann, J. A. Bagnell, P. Abbeel, and J. Peters, "An algorithmic perspective on imitation learning," *Foundations and Trends in Robotics*, vol. 7, no. 1–2, pp. 1–179, 2018.
- [14] A. Charland and B. Leroux, "Mobile application development: Web vs. native," *Communications of the ACM*, vol. 54, no. 5, pp. 49–53, 2011.
- [15] Ionic Team, "Flutter vs. ionic: Comparing cross-platform mobile frameworks," Technical blog post, Ionic, 2023. [Online]. Available: <https://ionic.io/blog/flutter-vs-ionic>
- [16] Supabase Inc., "Supabase documentation," Documentación técnica en línea, 2024. [Online]. Available: <https://supabase.com/docs>
- [17] J. Brooke, "SUS: A "quick and dirty" usability scale," *Usability Evaluation in Industry*, pp. 189–194, 1996.
- [18] F. D. Davis, "Perceived usefulness, perceived ease of use, and user acceptance of information technology," *MIS Quarterly*, vol. 13, no. 3, pp. 319–340, 1989.